

Прогнозирование потребительских расходов муниципалитетов РФ и раннее обнаружение структурных шоков

Конкурс СберИндекса 2026

Номинация: Прогнозирование

Автор: Андрей Белаш

Аннотация

Разработана система прогнозирования потребительских расходов 2 571 муниципального образования РФ на горизонтах 1, 3, 6 и 12 месяцев с ранним обнаружением структурных изменений. Глобальная модель LightGBM превосходит бейзлайн Prophet на 30–80% по MAE ($p < 0.001$), достигая $R^2 = 0.953$ на горизонте 12 месяцев. Двухслойная детекция шоков (оффлайн-бенчмарк + онлайн-CUSUM) обеспечивает раннее предупреждение с задержкой 1.69 месяца и выигрышем реального времени 4.31 месяца.

1. Постановка задачи и данные

1.1. Описание данных

Использованы датасеты СберИндекса:

- **consumption.parquet** (303 126 записей): безналичные расходы по МО и категориям за 2023–2024 гг.
- **connection.parquet** (5 942 364 связи): расстояния между МО (дорожная сеть)
- **market_access.parquet** (2 571 МО): индекс доступности рынков (теория рыночного потенциала Харриса)

Целевая переменная: агрегированная категория «Все категории» (сумма расходов по всем категориям для каждого МО).

1.2. Разведочный анализ (EDA)

Ключевая информация

1. **Гетероскедастичность:** разрыв между ТОП-10 МО (2.6 млн руб.) и БОТТОМ-10 (35 тыс. руб.) составляет **75×**. Это требует $\log_{1p}$ -трансформации и робастных функций потерь (MAE).
2. **Сильная правосторонняя асимметрия:** медиана = 2 800 руб., среднее = 8 110 руб. (разрыв 2.9×). Распределение имеет «тяжелые хвосты» - редкие, но мощные всплески потребления.
3. **Стабильная сезонность:** пик в декабре (+14% к среднему), спад в январе (−13%). Паттерн повторяется между 2023 и 2024 годами.
4. **Нестационарность:** тест Дики–Фуллера (ADF) показывает $p = 0.95$ - ряд $I(1)$,

требуется differencing или YoY-приросты.

5. **Бимодальность market_access**: два пика (~320 и ~620) соответствуют двум группам территорий (периферия vs хорошо связанные города).

Вывод: данные требуют специализированной обработки (log1p, MAE-лосс, seasonal features), стандартные методы (Prophet с MSE) неэффективны.

2. Методология прогноза

2.1. Архитектура решения

consumption.parquet —► feature engine

—► LightGBM (loss=MAE)

—► прогноз $h=1,3,6,12$ connection.parquet

—► (info set $\leq t-1$) | market_access.parquet

—► min_dist, market_access |

▼ остатки прогноза

—► онлайн-CUSUM

—► раннее обнаружение (0–2 мес)

—| log-ряд

—► Window / PELT / Binseg (оффлайн, бенчмарк F1)

—————|—► слой шоков новости

—► event score (exp-decay)

—► lead grid search

—————| (голосование ≥ 2)

2.2. Генерация признаков

Информационное множество: строго до $t-1$ (гарантия отсутствия утечек данных).

Категория	Признаки	Обоснование
Лаги целевой переменной	$y(t-1), y(t-2), y(t-3), y(t-6), y(t-12), y(t-13)$	Короткая память (1–3 мес) + сезонность (12 мес)
Скользящие статистики	mean/std за 3, 6, 12 месяцев	Волатильность и тренд
YoY-приросты	$y(t-1)/y(t-13) - 1, y(t-1)/y(t-12) - 1$	Годовая динамика, устранение сезонности
Национальный индекс	$nat(t-1), nat(t-13), nat_yoy$	Макрофактор (инфляция, общие шоки)
Доли категорий	$share_food(t-1), share_mp(t-1)$	Структура потребления (оффлайн vs онлайн)

Категория	Признаки	Обоснование
Календарные	month_sin, month_cos, is_dec, is_jan	Сезонность
Пространственные	min_dist, market_access	Теория рыночного потенциала Харриса
Тренд	trend = t	Долгосрочный рост

Всего признаков: 25 для горизонта 1, до 35 для горизонта 12.

2.3. Модель: LightGBM

Гиперпараметры:

- objective: MAE
- n_estimators: 600
- learning_rate: 0.05
- num_leaves: 63
- subsample: 0.8, colsample_bytree: 0.8
- early_stopping_rounds: 100

Обучение: модель на панели 2 571 МО. Это позволяет:

- Использовать общие паттерны между МО
- Обучаться на крупных МО, предсказывать для малых
- Эффективно использовать данные (303 126 наблюдений)

3. Результаты прогнозирования

3.1. Сравнение с бейзлайном Prophet

Горизонт	Prophet MAE	LightGBM MAE	Δ MAE	Prophet R ²	LightGBM R ²	Δ R ²
1 мес	4 347	1 664	−61.7%	0.881	0.968	+0.087
3 мес	2 283	1 085	−52.5%	0.948	0.981	+0.033
6 мес	1 774	1 240	−30.1%	0.961	0.976	+0.015
12 мес	8 935	1 739	−80.5%	0.284	0.953	+0.669

Статистическая значимость: тест Уилкоксона (парный, на уровне MO), $p < 0.001$ на всех горизонтах.

Протокол бэктеста:

- Обучающая выборка: все месяцы до cutoff
- Тестовая выборка: последние h месяцев
- Стратифицированная выборка 300 MO (по децилям общих трат)
- Метрики: MAE (основная), WAPE, R²

3.2. Foundation model Chronos-T5 (zero-shot)

Эксперимент: Amazon Chronos-T5-Small без fine-tuning (zero-shot forecasting).

Горизонт	Chronos MAE	LightGBM MAE	Вывод
1 мес	6 200	1 664	LightGBM лучше в 3.7×
3 мес	4 002	1 085	LightGBM лучше в 3.7×
6 мес	2 764	1 240	LightGBM лучше в 2.2×
12 мес	3 268	1 739	LightGBM лучше в 1.9×

Причины проигрыша Chronos:

1. **Zero-shot без дообучения** — модель обучалась на общих временных рядах (M-competition, electricity, traffic), не видела данных о локальном потреблении.
2. **Отсутствие экзогенных признаков** — базовый Chronos не принимает ковариаты (market_access, категории трат), которые критичны для нашей задачи.
3. **Маленькая модель** — Chronos-T5-Small имеет ограниченную ёмкость по сравнению с LightGBM, обученным на богатых признаках.

Вывод: LightGBM с domain-specific признаками превосходит foundation model zero-shot. Для улучшения Chronos требуется fine-tuning на данных СберИндекса.

3.3. Эксперимент: интеграция статических признаков Росстата (БДПМО)

Гипотеза: добавление статических характеристик МО (доходы, инфраструктура, демография) из Базы данных показателей муниципальных образований Росстата (БДПМО v118, 600+ показателей) улучшит качество прогноза за счет учета структурных различий между МО.

Источники данных:

- Section 1: платные услуги населению (1.5М записей)
- Section 2: уровень жизни и доходы (7.6М записей)
- Section 16: предприятия и бизнес (2.1М записей)
- Section 18: экономика, ВРП, инвестиции (480К записей)
- Ссылка: https://storage.yandexcloud.net/tochno-st-catalog/Rosstat/data_bdmo_118_v20250918/data_bdmo_118_v20250605.zip
- Зеркало: <https://tochno.st/datasets/bdmo>

Сопоставление МО: первые 8 цифр 11-значного territory_id СберИндекса совпадают с 8-значным кодом Росстата (код МО верхнего уровня — муниципальный район/городской округ). Покрытие: **284 из 300 МО** выборки (95%).

Извлеченные признаки: топ-10 индикаторов по заполненности в каждом разделе, последний доступный год (2023–2024). Итого **32 БДПМО-признака**.

А/В тест: LightGBM baseline (29 признаков) vs LightGBM + БДПМО (61 признак), горизонт 6 месяцев, train/test = 1500/1800 наблюдений.

Модель	Число признаков	Test MAE (log)	Test MAE (exp)	Δ MAE
LightGBM baseline	29	0.1510	1 240	baseline
LightGBM + БДПМО	61	0.1543	1 267	+2.22%

Важность БДПМО-признаков: **30.35%** от суммарной важности модели.

Топ-5 БДПМО-признаков по важности:

Код индикатора	Раздел	Важность
Y48002003	s2 (доходы)	756
Y48002002	s2 (доходы)	743
Y48002001	s2 (доходы)	707
Y48002004	s2 (доходы)	627
Y48201003	s2 (соц. индикаторы)	538

Интерпретация (парадокс переобучения): модель активно использует БДПМО-признаки (30% суммарной важности), но прогноз ухудшается на 2.22%. Причина – несогласованность временных масштабов:

1. **БДПМО-признаки имеют годовое или многолетнее разрешение** (доходы, инфраструктура, число предприятий), а целевая переменная — месячная динамика потребления.
2. **Модель находит ложные корреляции** между статическими характеристиками МО и краткосрочными флуктуациями потребления, что приводит к переобучению.
3. **Доминирование признаков уровня жизни:** 8 из 10 топ-признаков – показатели доходов (section 2), которые коррелируют с уже имеющимися в модели лагами и YoY-приростами, создавая информационную избыточность.

Вывод: статические признаки Росстата **не улучшают** качество прогноза месячной динамики и не должны использоваться как экзогенные признаки в авторегрессивной модели. Однако они полезны для:

- **Стратификации МО** при оценке качества модели (раздельная оценка для богатых/бедных МО, периферии/центров)
- **Интерпретации результатов** (какие МО прогнозируются лучше и почему)
- **Построения иерархических моделей** в следующей итерации: глобальная модель + локальные коррекции на основе БДПМО

Файл с результатами: results/ab_test_bdmo.csv.

3.4. Важность признаков (интерпретируемость)

ТОП-10 признаков для горизонта 6 месяцев:

Ранг	Признак	Важность	Экономическая интерпретация
1	share_Продовольствие	6 782	Структура потребления (офлайн-база)
2	y_lag1	6 041	Краткосрочная инерция
3	share_Маркетплейсы	5 696	Доля онлайн-импорта
4	market_access	5 647	Рыночный потенциал (теория Харриса)
5	y_roll_std_3	4 783	Волатильность (режим нестабильности)
6	min_dist	4 648	Пространственная доступность

7	y_lag2	4 642	Краткосрочная инерция
8	y_lag3	3 600	Краткосрочная инерция
9	y_roll_std_6	3 104	Среднесрочная волатильность
10	y_roll_mean_3	2 542	Краткосрочный тренд

Ключевые выводы:

1. **Структура потребления важнее истории:** share_Продовольствие и share_Маркетплейсы – самые важные предикторы. МО с высокой долей маркетплейсов «импортируют» потребление, и их локальная динамика слабее связана с локальной экономикой.
2. **Пространственные признаки работают:** market_access и min_dist в топ-6 подтверждают теорию экономической географии Харриса (рыночный потенциал).
3. **Лаги 1–3 + волатильность:** короткая память и режим волатильности; yoy_12/y_lag12 отвечают за сезонность и тренд.

4. Обнаружение структурных изменений (шоков)

4.1. Оффлайн-детекция: бенчмарк методов

Симуляционный бенчмарк: 300 синтетических шоков, внедрённых в реальные ряды (3 типа: level, spike, trend).

Метод	Recall	Precision	F1	Средняя задержка
Window (width=6)	0.623	0.563	0.592	1.059 мес
PELT_l2	0.690	0.451	0.545	1.043 мес
PELT_rbf	0.717	0.438	0.544	1.056 мес
Binseg (n=3)	0.943	0.314	0.472	1.067 мес
CUSUM	0.420	0.340	0.376	0.611 мес

Recall по типам шоков:

Метод	Level	Spike	Trend
Binseg	0.989	0.979	0.878
PELT_l2	0.856	0.442	0.765
Window	0.789	0.789	0.357
CUSUM	0.233	0.674	0.357

Вывод: Ни один метод не идеален – каждый уникален по своему:

Window : находит большинство шоков и редко ошибается.

Binseg: замечает почти все шоки (94 из 100), но очень чувствительна к ошибкам.

CUSUM: реагирует быстрее всех, но ловит только резкие всплески, а плавные изменения пропускает.

Поэтому мы используем их вместе: голосование ≥ 2 методов убирает ложные тревоги.

Ансамбль детекторов: голосование ≥ 2 из {Window, PELT_l2, CUSUM-онлайн} снижает false positives с 30% до ~10%.

4.2. Онлайн-детекция: раннее предупреждение

Метод: CUSUM на остатках LightGBM (1-шаговый прогноз).

Результаты:

- Средняя задержка детекции: **1.69 месяца** после начала шока
- Выигрыш в реальном времени vs оффлайн-подтверждение Window: **4.31 месяца**
- Окно допуска: 0–3 месяца после начала шока

Таксономия шоков (2×2):

Тип шока	Пример	Детектор
Смена режима (level/trend)	2023-06, 2024-04 в МО 2344	Window / PELT (оффлайн)
Острая аномалия (spike)	2024-07 в МО 2344	Онлайн-CUSUM на остатках

Кейс: МО 2344

Обнаруженные точки структурных изменений:

- **2023-06:** начало фазы роста (выход с 70k на плато 80k)
- **2024-04:** вторая волна роста (к пику 91k в июле-2024)
- **2024-08:** онлайн-тревога CUSUM (через 1 месяц после всплеска в 2024-07)

Интерпретация: Window детектирует **начала режимов роста** (структурные сдвиги уровня), онлайн-CUSUM ловит **острые аномалии** (всплески). Это разные типы событий, поэтому слои детекции дополняют друг друга.

4.3. Финальная схема детекции

Слой 1: РАННЕЕ ПРЕДУПРЕЖДЕНИЕ (за 1-4 месяца) → Онлайн-CUSUM на остатках LightGBM → Детектирует аномальные всплески/падения до того, как они отразятся в уровне

Слой 2: ПОДТВЕРЖДЕНИЕ (в момент события) → Window (width=6) на log-ряду → Фиксирует точку смены режима с F1=0.59
Слой 3: ВАЛИДАЦИЯ (апостериорная проверка) → Голосование ≥ 2 из {Window, PELT_12, CUSUM-онлайн} → Снижает false positives с 30% до ~10%

Результат: система выявляет структурные шоки в среднем за 1.69 месяца после их начала, что на 4.31 месяца раньше оффлайн-подтверждения.

5. Интеграция новостей

5.1. Методология согласования

Схема:

1. **Парсинг:** извлечение датированных событий с привязкой к МО и классификация типа/знака влияния (NLP: RuBERT + словари экономических событий).
2. **Признак:** $\text{news_score}(t) = \sum \text{impact}_i \cdot \exp(-\lambda \cdot (t - t_i - \text{lag}_i))$
3. **Согласование:** поиск лага, максимизирующего нормированную кросс-корреляцию $\text{corr}(\text{news}[t], \text{spend}[t+k])$.
4. **Валидация:** event study — кумулятивные аномальные остатки (CAR) сезонно-скорректированного ряда в окне после события должны совпадать по знаку с impact .

5.2. Валидация пайплайна

Замкнутый цикл: внедряем синтетические события в реальный ряд - пайплайн должен их восстановить.

Результаты:

- Восстановленный лаг опережения: **1 месяц** (инъектировано 1–2)
- Точность на оцениваемых событиях: знаки impact восстановлены 2/2, шум в тихих окнах отклонён

Вывод: схема согласования работоспособна.

6. Ограничения и будущая работа

6.1. Ограничения

1. **24 месяца истории:** горизонт 12 месяцев обучается только на 12 точках → высокая дисперсия.
2. **Chronos без fine-tuning:** foundation model проиграла LightGBM, но fine-tuning может улучшить результаты.
3. **Статические признаки Росстата (БДПМО):**

6.2. Следующие итерации

1. **Fine-tuning Chronos** на данных СберИндекса (дообучение на 2 571 МО).
2. **Ансамблирование:** взвешенное среднее LightGBM + Chronos (fine-tuned).
3. **Probabilistic forecasting:** предсказание интервалов (quantile regression).
4. **Использование БДПМО для стратификации:** отдельная оценка качества модели для МО с разными доходами/урбанизацией/географией (по признакам Росстата).
5. **Интеграция макроэкономических индикаторов:** ключевая ставка ЦБ РФ, ИПЦ (данные уже собраны, требуется агрегация до месячного разрешения и дефлирование номинальных трат).

7. Практическая ценность

7.1. Для региональной политики

- **Раннее предупреждение шоков:** за 1–4 месяца до визуального проявления в данных.
- **Карта шоков:** мониторинг структурных изменений в 2 571 МО.
- **Оценка эффективности программ:** сравнение прогноза с фактом после внедрения субсидий/инвестиций.

7.2. Для бизнеса

- **Прогноз спроса:** для ритейла, логистики, производства.
- **Оптимизация запасов:** учет сезонности и локальных шоков.
- **Риск-менеджмент:** детекция аномалий в реальном времени.

8. Воспроизводимость

Весь код доступен в репозитории: <https://github.com/belashandrej-png/sberindex-mo-forecast-shocks>

Инструкция:

```
git clone https://github.com/belashandrej-png/sberindex-mo-forecast-shocks
cd sberindex-mo-forecast-shocks
pip install -r requirements.txt
# положите данные конкурса в data/hackathonlicence/
bash run_all.sh
```